昇腾 910B 算子优化进展

围绕 FlagGems 昇腾算子，完成了早期性能优化与正确性修复、低于 0.8× 的正式对象优化，并将诊断和有效方法固化为无人值守工作流。

一、Excel 中已超过验收线的算子：继续优化与正确性修复

除最后一列外，性能数字均为相对 PyTorch 的加速比；最后一列表示 HG-KDA 相对 FlagGems 的加速比。

算子	Excel 记录	原版 FlagGems	修复版 FlagGems	HG-KDA	HG-KDA 相对 FlagGems
mse_loss_backward	1.1688×	1.11×，27/27 通过	—	1.34×	1.20×
t_copy	3.0894×	1.96×，9/9 通过	—	3.43×	1.73×
prelu_kernel_backward	1.8152×	正确性失败，3/21 通过	0.49×	0.95×	1.97×
batch_norm_backward	4.3885×	正确性失败，9/30 通过	2.32×	5.01×	2.19×
smooth_l1_loss_backward	2.2139×	正确性失败，290/291 通过	2.17×	3.48×	1.61×

mse_loss_backward、t_copy 与原版 FlagGems 对比，后三项与正确性修复后的 FlagGems 对比。五项 HG-KDA 版本均通过完整测试；prelu_kernel_backward 超过 0.8× 验收线，但仍略慢于 PyTorch。

早期五项使用的历史 FlagGems 原源码锁定在上游提交 `4772d816bc5d52d37c4718f36adf377d81261f83`；执行测试的本机 checkout 为 `349011a9cd4b4180ad170515918dff7ff338e346`，包含本机评测适配，五份实际调用的原算子源码与锁定上游逐字节一致。后三项修复通过 KGS implementation override 注入，未改共享 checkout。

Excel 未注明提交号和完整测试合同，因此保留为历史记录，不把它当作本机复测值。

主要改进为 mse_loss_backward 扩大分块与连续输入快路径、t_copy 按形状分块与多块处理、prelu_kernel_backward 融合梯度与补偿归约、batch_norm_backward 按形状分流与归约融合、smooth_l1_loss_backward 修复 NaN 并提前确定 beta 相关计算。这部分已归档，作为流程与优化方法验证成果。

证据：原版 FlagGems 对照、后三项修复版 FlagGems 对照。

二、验收记录低于 0.8× 的算子：四项已达标

性能数字均为相对 PyTorch 的加速比。FlagGems 实测与 HG-KDA 均通过表中完整评测。

算子	Excel 记录	FlagGems 实测	HG-KDA	完整评测	关键优化
logaddexp2	0.3218×	0.231×	1.262×	36/36	稳定公式、连续快路径、精度安排和多块处理
amin	0.5536×	0.308×	0.934×	27/27	直接归约，整除去边界判断，精度与缓冲优化
matmul_bias_activation	0.5408×	0.439×	0.909×	42/42	FP32 双输出块复用 A，扩大 K 分块，融合 bias/激活
narrow_copy	0.0138×	约0.010×	1.118×	33/33	小输入 CANN DMA，大输入 Triton

FlagGems 实测使用 **flagos-ai/FlagGems 的固定 master 提交** `d6a8eec473517a3d68157b208eb9c057eb1d4c50`，源码在 `third_party/FlagGems/`。该版本与早期五项使用的历史版本不同。**amin、narrow_copy 的 FlagGems 版本含启动兼容修复**，用于处理大输入启动问题，保留原内核计算；logaddexp2 和 matmul_bias_activation 使用原版实现。

四项 HG-KDA 均超过 0.8×。matmul_bias_activation 与 narrow_copy 使用最新真实生成候选的两次复验较慢值，其他两项使用本轮固定最佳源码复验较慢值。FlagGems 实测来自已归档的 master 复测，HG-KDA 数据来自后续完整复验，各自取完整性能 case 的几何平均。narrow_copy 计时包含 DMA 与 kernel，其他为设备 kernel。Excel 是历史筛选记录，各批次实际成绩以自己的完整合同为准。

证据：前三项 FlagGems 实测、narrow_copy 兼容版 FlagGems 实测、四项历史最佳复验、最新 matmul_bias_activation 生成与复验、最新 narrow_copy 生成与复验。

三、HG-KDA：独立 Profiling 优化工作流

HG-KDA 当前实现是 **Markdown 优化知识＋Python/Bash 控制器＋CC/DeepSeek 模型调用** 的无人值守工作流，尚未封装为标准 skill。服务器通过 tmux 运行，自动执行“选择慢 case → 采集真机 profiling → 组织诊断与修改建议 → 生成源码 → 完整测试 → 保留最佳 → 两次复验”，控制端关机不影响运行。

已固化四个算子的有效建议、失败经验和约束，并保存提示词、知识快照、模型响应、源码 SHA 和原始评测证据。四个最佳源码已全部复现；最新生成批次中，amin 最终较起点提升约 0.59%，matmul_bias_activation 提升约 4.36%。logaddexp2 本批没有生成有效提升，narrow_copy 最终较纯 Triton 起点提升约 40.10%；模型重新生成结果单独报告。

相对原生 KG，本轮增加的是可重用的 910B/算子诊断知识、历史失败约束、实现变更检查，以及独立复验与证据核验。复杂执行路径分析、IR/模拟器补测与诊断策略尚未全部自动化；当前使用真实延迟及 PipeUtilization，数值 Roofline 尚未建立。

工作流位置：tools/profiling/，运行方式见四算子工作流。四项生成实验与完整复验均已归档，证据已完成 Windows、GitHub、910B 三端同步和 LFS 实体核验。